

1. Что в целом удалось сделать

В работе я последовательно разобрал датасет с химическими дескрипторами и тремя таргетами (IC50, CC50, SI), провёл EDA, подготовил данные и построил восемь моделей: три задачи регрессии и четыре задачи классификации с разными порогами для IC50, CC50 и SI.

Для каждой задачи я не просто обучил одну модель, а сравнил несколько подходов: от простых линейных методов до ансамблей деревьев и градиентного бустинга, с подбором гиперпараметров через RandomizedSearchCV и отдельной валидационной и тестовой выборкой.

2. Регрессия: IC50, CC50, SI

IC50

По IC50 видно, что простая линейка с задачей не справляется: R^2 у неё заметно ниже 0.3 и RMSE выше 300, то есть модель даёт слишком грубый прогноз.

После перехода к ансамблям качество выросло: у настроенного RandomForestRegressor на валидации MAE = 178, RMSE = 261, R^2 = 0.39, а на тесте MAE = 232, RMSE = 429, R^2 = 0.45. XGBRegressor даёт очень близкие (чуть лучшие) цифры: на валидации MAE = 171, RMSE = 258, R^2 = 0.40, на тесте MAE = 229, RMSE = 438, R^2 = 0.42. Ансамбли научились различать соединения с низкой и высокой IC50, но до детального точного прогноза ещё далеко, что для биологических данных ожидаемо.

Практически эти модели годятся как фильтр: можно отсекают явно «слабые» по активности структуры и не гнать их в дорогие тесты, а не пытаться предсказать IC50 «до миллимоля».

CC50

Для CC50 ситуация лучше: лучшая модель XGBRegressor после подбора гиперпараметров на валидации даёт MAE = 274, RMSE = 373, R^2 = 0.48, а на тесте MAE = 285, RMSE = 453 и R^2 = 0.60.

Это уже приличное объяснение дисперсии цитотоксичности: модель отличает более токсичные соединения от менее токсичных, а разрыв между валидацией и тестом умеренный, без явного переобучения.

SI

С SI в исходной шкале регрессия провалилась: R^2 был отрицательным, а RMSE на тесте превышал 1300 при относительно умеренном MAE, то есть экстремальные значения селективности ломали квадратичную метрику.

После перехода к логарифму SI ($SI_{\log} = \log_{10}(SI)$) качество стало приемлемым: для RandomForestRegressor на лог-таргете на валидации MAE = 0.82, RMSE = 1.05, R^2 = 0.32, а на тесте MAE = 0.91, RMSE = 1.21, R^2 = 0.40; XGBRegressor показывает очень похожие результаты.

В лог-шкале модель уже может предсказывать, насколько селективность соединения отклоняется от среднего уровня, и не рушится на выбросах.

Рекомендации по регрессии:

Для IC50 и CC50 стоит использовать градиентный бустинг или случайный лес как основной инструмент количественного предсказания, а линейные модели оставить как baseline и более интерпретируемую «справку».

Для SI регрессию нужно строить в лог-шкале; при этом даже после логарифмирования задача остаётся сложной (R^2 около 0.4), и регрессию SI разумно рассматривать как вспомогательный источник информации.

3. Классификация: пороги по IC50, CC50 и SI

IC50 > медианы

Для задачи «IC50 > медианы» XGBClassifier после RandomizedSearchCV показал на тесте accuracy = 0.72, f1_macro = 0.72, ROC-AUC = 0.80, при этом на валидации метрики немного ниже, но близки (ROC-AUC = 0.75).

Логистическая регрессия и простые деревья отстают, поэтому бустинг даёт лучший баланс качества и стабильности и подходит как основная модель для этой задачи.

CC50 > медианы

Для CC50 > медианы лучше себя показал RandomForestClassifier: на валидации accuracy = 0.76, f1_macro = 0.76, ROC-AUC = 0.85; XGBClassifier немного уступает по всем трём метрикам.

На тесте лес также держит достойный уровень (accuracy = 0.71, f1_macro = 0.71, ROC-AUC = 0.83) без сильного расхождения с валидацией. Это делает лес предпочтительной моделью-классификатором для «CC50 > медианы».

SI > медианы

В задаче SI > медианы разделяются соединения с селективностью чуть ниже и чуть выше медианы, поэтому задача сложнее.

После учёта логарифма SI и настройки ансамблей получились такие результаты: для XGBClassifier на валидации accuracy = 0.69, f1_macro = 0.69, ROC-AUC = 0.77; на тесте RandomForestClassifier даёт accuracy = 0.64, f1_macro = 0.63, ROC-AUC = 0.68, а XGBClassifier — accuracy = 0.63, f1_macro = 0.63, ROC-AUC = 0.70.

Качество здесь умеренное, но модели устойчиво лучше случайного угадывания и позволяют примерно отделить более селективные соединения от остальных.

SI > 8

В задаче SI > 8 отбираются действительно высокоселективные соединения.

Здесь ансамбли показывают сопоставимое качество на кросс-валидации (ROC-AUC около 0.72), а по итоговым метрикам:

RandomForestClassifier: на валидации accuracy = 0.67, f1_macro = 0.61, ROC-AUC = 0.69; на тесте accuracy = 0.72, f1_macro = 0.67, ROC-AUC = 0.74.

XGBClassifier: на валидации accuracy = 0.69, f1_macro = 0.65, ROC-AUC = 0.71; на тесте accuracy = 0.75, f1_macro = 0.70, ROC-AUC = 0.75.

XGBClassifier даёт лучшие значения F1 и ROC-AUC на тесте, поэтому именно его логично выбрать как основную модель-фильтр для SI > 8.

Рекомендации по классификации:

Для задач «> медианы» по IC50 и CC50 ансамбли (RandomForest/XGB) дают качественный и устойчивый скрининг по активности и токсичности.

Для SI > медианы модель можно использовать как вспомогательный инструмент приоритизации, а не как единственный критерий отбора.

Для SI > 8 XGBClassifier уже даёт достаточно уверенный фильтр высокоселективных молекул, который имеет смысл применять перед дорогими лабораторными экспериментами.

4. Общие закономерности по признакам

По ходу EDA и моделирования проявились несколько закономерностей:

Таргеты IC50, CC50 и SI коррелируют между собой, что отражает связь активности, токсичности и селективности, причём SI выражается через IC50 и CC50.

Существенный вклад в качество моделей вносят дескрипторы, связанные с размером, полярностью и структурой молекулы (молекулярный вес, VSA-характеристики, BCUT, EState и фрагментные признаки).

Логарифмирование SI и аккуратная работа с выбросами и пропусками оказывают критическое влияние на устойчивость и адекватность моделей.

5. Что имеет смысл делать дальше

Если рассматривать продолжение исследования, а не только выполнение курсовой, следующие шаги выглядят логично:

Упростить и осмысленно сократить набор признаков: сгруппировать дескрипторы по химическому смыслу, убрать сильно коррелирующие и малоинформативные признаки, оставить ядро, которое даёт основной вклад в качество.

Использовать более продвинутый тюнинг гиперпараметров (Optuna, Bayesian optimization) для XGB и леса в ключевых задачах (IC50, CC50, SI > 8).

Переформулировать задачи по SI: попробовать многоклассовую классификацию по уровням селективности (низкий/средний/высокий), тестировать разные пороги, добавить робастные методы для регрессии.

Сделать акцент на интерпретации: посчитать важности признаков и SHAP-значения для лучших моделей, чтобы дать химикам конкретные гипотезы по структурным мотивам, повышающим активность, снижающим токсичность и увеличивающим селективность.

6. Итог

Итоговая картина: построен полный цикл от EDA до рабочих моделей для прогнозирования активности (IC50), токсичности (CC50) и селективности (SI) с понятным уровнем качества, здоровой интерпретацией и предложениями по дальнейшему развитию.

Модели для IC50 и CC50 в регрессии и классификации по медиане уже дают ощутимый выигрыш относительно простых подходов и годятся для раннего скрининга, а задачи по SI (особенно $SI > 8$) позволяют приоритизировать наиболее интересные молекулы и экономить ресурсы экспериментов, не подменяя собой лабораторные измерения.